

Aufgabe zu HashSets

Erik Imgrund, TINF19B1

24. Mai 2020

1 Grundlegendes

1.1 Verwendete Verfahren

Zur Kollisionsauflösung wurden Direct Chaining, Separate Chaining, Linear Probing, Quadratic Probing, Triangular Probing und ein Coalesced Table implementiert. Als Hashfunktionen wurden einmal der simple ModHash und MulHash aus der Vorlesung implementiert, sowie ein gebräuchlicher XorShiftHash. Bei dem XorShiftHash wird die Zahl mit einer Konstante multipliziert, bitweise verschoben und dann über ein bitweises Exklusiv-Oder mit der nicht-verschobenen Variante kombiniert.

1.2 Aufgabestellung

In der Aufgabe wurde beschrieben, dass mit konstanter Anzahl an Buckets und unter verschiedenen Lastfaktoren die Anzahl an Kollisionen pro Zugriff und „was für sinnvoll gehalten wird“ gemessen werden soll. Für sinnvoll wird gehalten, die Zugriffszeit zu messen, dementsprechend wurde dieses auch getan.

Für sinnvoll wurde ebenfalls gehalten, die Messungen unter anderen Bedingungen zu wiederholen. Da jeder Bucket eines OpenAddressingTables nur 8 Byte groß ist, einer eines CoalescedTables jedoch 24 Byte könnte bei gleichem Speicherverbrauch ein 3 mal so großer OpenAddressingTable erstellt werden. Die Messung mit konstanter Anzahl an Buckets benachteiligt stark OpenAddressingTables, deswegen wurde eine zweite Messreihe mit angepassten Größen durchgeführt. Die Herleitung der verwendeten Anzahl an Buckets pro Verfahren ist im Folgenden zu finden.

1.3 Anzahl an Buckets in Abhängigkeit der geforderten Speichergröße

Die Speichergröße wird festgelegt auf die Größe eines OpenAddressingTables mit 2^{15} Buckets, das entspricht 262kB. Für den CoalescedTable sind Buckets 24B groß, also werden $\frac{262kB}{24B} = 10922$ Buckets verwendet.

Für DirectChainingTables ist ein Bucket ebenfalls 8 Byte groß, jedoch werden zusätzlich für jedes Element 16B alloziert, daher wird vom vorhandenen Speicherlimit zuerst die Anzahl der Elemente multipliziert mit der Größe eines Elements abgezogen und danach die größtmögliche Anzahl an Buckets im Restspeicherplatz alloziert.

Für SeparateChainingTables ist das Verfahren komplizierter, da bloß Speicherplatz für jedes Element, welches mit einem anderen kollidiert Extra-Platz alloziert werden muss. Dafür wird dafür ausgegangen, dass grundlegend jedes eingefügte Element 16B Speicherplatz benötigt, jeder leer gebliebene Bucket am Ende des Einfügens jedoch auch 16B. Die Wahrscheinlichkeit, dass ein bestimmter Bucket nach dem Einfügen von n Elementen noch leer ist ist direkt abhängig von der Anzahl der Buckets m und ergibt sich als $p = \left(\frac{m-1}{m}\right)^n$. Der Erwartungswert leerer Buckets ist somit $E = m \left(\frac{m-1}{m}\right)^n$ und der verwendete Platz ist $N = 16B \left(n + m \left(\frac{m-1}{m}\right)^n\right)$. Diese Gleichung wird numerisch für ein möglichst großes m gelöst, für welches $N \leq 262kB$ gilt.

2 Ergebnisse

2.1 Ergebnisse bei Messung nach Aufgabenbedingungen

Name	50%	90%	95%	100%
Quadratic Mul	0,42	1,73	2,35	8,8
Quadratic Mod	0,44	1,72	2,32	10,38
Quadratic XOR	0,43	1,71	2,36	9,54
Linear Mul	0,43	1,87	2,60	8,93
Linear Mod	0,42	1,87	2,64	10,51
Linear XOR	0,44	1,91	2,59	9,83
Triangular Mul	0,42	1,71	2,36	8,85
Triangular Mod	0,43	1,74	2,37	8,12
Triangular XOR	0,43	1,69	2,35	9,71
Direct Mul	0,25	0,44	0,47	0,50
Direct Mod	0,26	0,45	0,48	0,50
Direct XOR	0,25	0,45	0,48	0,51
Separate Mul	0,24	0,44	0,48	0,50
Separate Mod	0,25	0,45	0,47	0,50
Separate XOR	0,25	0,46	0,48	0,51
Coalesced Mul	1,17	1,66	1,74	1,80
Coalesced Mod	1,16	1,66	1,72	1,79
Coalesced XOR	1,17	1,65	1,72	1,79

Tabelle 2.1: Durchschnittliche Kollisionen bei Zugriff mit Erfolg

Name	50%	90%	95%	100%
Quadratic Mul	1,14	9,50	19,51	-
Quadratic Mod	1,14	9,60	19,73	-
Quadratic XOR	1,13	9,62	19,73	-
Linear Mul	1,16	11,14	22,45	-
Linear Mod	1,16	11,01	23,09	-
Linear XOR	1,17	11,14	24,24	-
Triangular Mul	1,12	9,72	19,94	-
Triangular Mod	1,13	9,69	19,68	-
Triangular XOR	1,13	9,74	19,58	-
Direct Mul	0,50	0,90	0,95	0,99
Direct Mod	0,50	0,91	0,94	1,00
Direct XOR	0,50	0,90	0,95	0,99
Separate Mul	0,50	0,90	0,95	0,99
Separate Mod	0,50	0,90	0,96	1,00
Separate XOR	0,50	0,90	0,95	1,00
Coalesced Mul	2,19	2,84	2,97	3,09
Coalesced Mod	2,18	2,84	2,94	3,10
Coalesced XOR	2,18	2,80	2,93	3,06

Tabelle 2.2: Durchschnittliche Kollisionen bei Zugriff mit Erfolg

Name	50%	90%	95%	100%
Quadratic Mul	15,69	22,84	26,38	36,12
Quadratic Mod	7,95	12,98	17,40	26,56
Quadratic XOR	11,11	19,13	13,36	26,82
Linear Mul	22,36	18,60	18,47	28,08
Linear Mod	7,07	11,77	12,42	21,82
Linear XOR	12,34	16,40	13,42	42,18
Triangular Mul	12,73	22,71	19,54	44,04
Triangular Mod	6,40	11,02	11,95	20,09
Triangular XOR	8,25	14,00	13,82	27,00
Direct Mul	29,27	18,00	18,34	18,84
Direct Mod	11,03	30,81	15,37	15,18
Direct XOR	15,89	16,96	17,24	19,36
Separate Mul	11,61	15,89	22,11	24,84
Separate Mod	8,80	12,73	25,38	13,32
Separate XOR	10,45	14,45	14,89	21,30
Coalesced Mul	13,39	22,21	18,46	18,33
Coalesced Mod	10,66	15,11	16,11	15,69
Coalesced XOR	12,40	23,61	16,96	18,37

Tabelle 2.3: Durchschnittliche Kollisionen bei Zugriff mit Erfolg

Name	50%	90%	95%	100%
Quadratic Mul	26,70	54,74	63,56	-
Quadratic Mod	29,43	34,32	47,58	-
Quadratic XOR	23,65	33,29	42,50	-
Linear Mul	28,92	43,14	49,96	-
Linear Mod	17,75	34,40	41,58	-
Linear XOR	21,51	32,34	45,58	-
Triangular Mul	24,55	45,98	51,65	-
Triangular Mod	16,08	29,74	42,57	-
Triangular XOR	19,55	33,58	45,38	-
Direct Mul	31,02	30,57	31,61	31,03
Direct Mod	19,57	38,78	26,45	26,70
Direct XOR	23,20	44,13	29,42	30,70
Separate Mul	23,49	28,22	30,52	31,97
Separate Mod	27,56	23,86	34,34	24,72
Separate XOR	22,51	27,11	27,73	29,54
Coalesced Mul	18,64	33,36	31,12	32,21
Coalesced Mod	15,82	25,53	32,82	29,31
Coalesced XOR	17,42	34,61	30,27	32,26

Tabelle 2.4: Durchschnittliche Kollisionen bei Zugriff mit Erfolg

2.2 Ergebnisse bei Messung nach für sinnvoll gehaltenen Bedingungen




Abbildung 2.1: Durchschnittliche Anzahl an Kollisionen bei fehlschlagenden Zugriffen




Abbildung 2.2: Durchschnittliche Anzahl an Kollisionen bei erfolgreichen Zugriffen




Abbildung 2.3: Durchschnittliche Zugriffszeit bei fehlschlagenden Zugriffen in ns




Abbildung 2.4: Durchschnittliche Zugriffszeit bei erfolgreichen Zugriffen in ns

3 Interpretation der Ergebnisse

3.1 Interpretation der Ergebnisse unter den Bedingungen der Aufgabenstellung

3.2 Interpretation der Ergebnisse unter für sinnvoll gehaltenen Bedingungen

4 Programm- bzw. Quellcode

4.1 Quellcode

Der komplette Quellcode inklusive Graph-Generierung wurde in Rust geschrieben. Die Ausführung sollte über das Tool „cargo“ durchgeführt werden. Das erhaltene Executable gibt die gemessenen Daten in Tabellenform in stdout aus, erstellt eine csv-Datei mit den Daten und erstellt 4 Graphen. Die Konfiguration der Messung erfolgt über den Quellcode.

Da gefordert wurde, dass der komplette Quellcode im Dokument enthalten ist, hier eine Sektion mit demselben. Alternativ kann das Projekt auch angenehm auf GitHub unter ¹ eingesehen werden. Die Dokumentation und Erklärung des Codes ist über „Doc Comments“ realisiert, kann also im Code durch Kommentare komplett eingebettet gelesen werden. Alternativ kann auch über den Aufruf des Befehls `cargo doc` eine HTML-Dokumentation generiert werden.

4.2 Vollständiger Quellcode

Listing 4.1: main.rs

```
extern crate gnuplot;
extern crate rand;

pub mod hashset;
pub mod logging;

use hashset::*;
use logging::*;
use rand::{thread_rng, Rng};
use std::time::Instant;
```

¹<https://github.com/imkgerC/uni-theo2-hashset>

```

/// Helper function to get an instance of a DefaultHashTableBuilder for the given Hash
fn get_builder<T: PartialEq + 'static, H: 'static + HashTable<T> + Default>(
) -> Box<dyn HashTableBuilder<T>> {
    Box::new(DefaultHashTableBuilder::<T, H>::default())
}

const RESIZE_TO_MAKE_FAIR: bool = true;
const LOAD_FACTORS: [f64; 32] = [
    0.01, 0.02, 0.03, 0.04, 0.05, 0.06, 0.07, 0.08, 0.09, 0.1, 0.11, 0.12, 0.13, 0.14,
    0.17, 0.18, 0.19, 0.2, 0.21, 0.22, 0.23, 0.24, 0.25, 0.26, 0.27, 0.28, 0.29, 0.3,
];
const ITERATIONS_PER_LOAD_FACTOR: usize = 50;

fn main() {
    #[rustfmt::skip]
    let tables: Vec<(Box<dyn HashTableBuilder<u32>>, String)> = vec![
        // (get_builder::<u32, OpenAddressingTable::<u32, QuadraticProber, MulHash>>(), "Open Mul".to_string()),
        // (get_builder::<u32, OpenAddressingTable::<u32, QuadraticProber, ModHash>>(), "Open Mod".to_string()),
        // (get_builder::<u32, OpenAddressingTable::<u32, QuadraticProber, XorShiftHash>>(), "Open XorShift".to_string()),
        // (get_builder::<u32, OpenAddressingTable::<u32, LinearProber, MulHash>>(), "Linear Mul".to_string()),
        // (get_builder::<u32, OpenAddressingTable::<u32, LinearProber, ModHash>>(), "Linear Mod".to_string()),
        (get_builder::<u32, OpenAddressingTable::<u32, LinearProber, XorShiftHash>>(), "Linear XorShift".to_string()),
        // (get_builder::<u32, OpenAddressingTable::<u32, TriangularProber, MulHash>>(), "Triangular Mul".to_string()),
        // (get_builder::<u32, OpenAddressingTable::<u32, TriangularProber, ModHash>>(), "Triangular Mod".to_string()),
        (get_builder::<u32, OpenAddressingTable::<u32, TriangularProber, XorShiftHash>>(), "Triangular XorShift".to_string()),
        // (get_builder::<u32, DirectChainingTable::<u32, MulHash>>(), "Direct Mul".to_string()),
        // (get_builder::<u32, DirectChainingTable::<u32, ModHash>>(), "Direct Mod".to_string()),
        (get_builder::<u32, DirectChainingTable::<u32, XorShiftHash>>(), "Direct XorShift".to_string()),
        // (get_builder::<u32, SeparateChainingTable::<u32, MulHash>>(), "Separate Mul".to_string()),
        // (get_builder::<u32, SeparateChainingTable::<u32, ModHash>>(), "Separate Mod".to_string()),
        (get_builder::<u32, SeparateChainingTable::<u32, XorShiftHash>>(), "Separate XorShift".to_string()),
        // (get_builder::<u32, CoalescedTable::<u32, MulHash>>(), "Coalesced Mul".to_string()),
        // (get_builder::<u32, CoalescedTable::<u32, ModHash>>(), "Coalesced Mod".to_string()),
    ];
}

```

```

        (get_builder::

```

```
fn get_stats(builder: &dyn HashTableBuilder<u32>, fill: f64) -> (f32, f64, f32, f64) {
    let fill = f64::min(fill * ELEMENT_COUNT as f64, ELEMENT_COUNT as f64) as usize;
    get_stats_rec(builder, fill, 0)
}

fn get_stats_rec(
    builder: &dyn HashTableBuilder<u32>,
    fill: usize,
    attempt: usize,
) -> (f32, f64, f32, f64) {
    let random_samples = 1_usize << 16;
    let repetitions_successful = 1;

    let mut table = builder.build();
    if RESIZE_TO_MAKE_FAIR {
        table.as_mut().resize_to_bytes(ELEMENT_COUNT << 3, fill);
    }
    let mut rng = thread_rng();
    let mut inserted_nums = Vec::with_capacity(fill);
    for _ in 0..fill {
        let num = rng.gen();
        inserted_nums.push(num);
        if !HashTable::insert(table.as_mut(), &num) {
            if attempt > 100 {
                return (std::f32::NAN, std::f64::NAN, std::f32::NAN, std::f64::NAN);
            }
            return get_stats_rec(builder, fill, attempt + 1);
        }
    }
    let mut ns = 0_usize;
    let mut nf = 0_usize;
    let mut cs = 0_usize;
    let mut cf = 0_usize;
```

```
let start_time = Instant::now();
for x in &inserted_nums {
    table.as_mut().has(x);
}
let duration_s = start_time.elapsed().as_nanos();
let start_time = Instant::now();
for _ in 0..random_samples {
    let num = rng.gen();
    table.as_mut().has(&num);
}
let duration_f = start_time.elapsed().as_nanos();
for _ in 0..repetitions_successful {
    for x in &inserted_nums {
        HashTable::reset_collisions(table.as_mut());
        if HashTable::has(table.as_mut(), x) {
            ns += 1;
            cs += HashTable::get_collisions(table.as_ref());
        } else {
            println!("did not find what we would need to find");
            nf += 1;
            cf += HashTable::get_collisions(table.as_ref());
        }
    }
}
for _ in 0..(1_usize << 16) {
    let num = rng.gen();
    HashTable::reset_collisions(table.as_mut());
    if HashTable::has(table.as_mut(), &num) {
        ns += 1;
        cs += HashTable::get_collisions(table.as_ref());
    } else {
        nf += 1;
        cf += HashTable::get_collisions(table.as_ref());
    }
}
```



```
}
let nf = nf as f32;
let cf = cf as f32;
let ns = ns as f32;
let cs = cs as f32;
(
    (cs / ns),
    (duration_s as f64 / fill as f64),
    (cf / nf),
    (duration_f as f64 / random_samples as f64),
)
}
```

Listing 4.2: mod.rs

```
mod chainingtable;
mod coalescedtable;
mod hashing;
mod openaddressing;
mod probing;

pub use chainingtable::*;
pub use coalescedtable::*;
pub use hashing::*;
pub use openaddressing::*;
pub use probing::*;
use std::marker::PhantomData;

pub const ELEMENT_COUNT: usize = 1 << 15;

pub trait HashTable<T> {
    fn has(&mut self, val: &T) -> bool;
    fn reset_collisions(&mut self);
    fn get_collisions(&self) -> usize;
    fn insert(&mut self, val: &T) -> bool;
```

```
fn resize_to_bytes(&mut self, bytes: usize, elements: usize);
}

pub trait HashTableBuilder<T> {
    fn build(&self) -> Box<dyn HashTable<T>>;
}

pub struct DefaultHashTableBuilder<T: PartialEq, H: HashTable<T> + Default> {
    table: PhantomData<H>,
    t: PhantomData<T>,
}

impl<T: PartialEq, H: 'static + HashTable<T> + Default> HashTableBuilder<T>
    for DefaultHashTableBuilder<T, H>
{
    fn build(&self) -> Box<dyn HashTable<T>> {
        Box::new(H::default())
    }
}

impl<T: PartialEq, H: HashTable<T> + Default> Default for DefaultHashTableBuilder<T,
    fn default() -> Self {
        Self {
            table: PhantomData,
            t: PhantomData,
        }
    }
}
```

Listing 4.3: hashing.rs

```
pub struct ModHash;
impl Hasher<u32> for ModHash {
    fn hash(val: &u32, max: usize) -> usize {
        *val as usize % max
    }
}
```

```
    }
}

pub struct MulHash;
const PHI: f64 = 0.618_033_988_75;
impl Hasher<u32> for MulHash {
    fn hash(val: &u32, max: usize) -> usize {
        let val = *val as f64;
        (max as f64 * ((val * PHI) - f64::floor(val * PHI))) as usize
    }
}

pub struct XorShiftHash;
impl Hasher<u32> for XorShiftHash {
    fn hash(val: &u32, max: usize) -> usize {
        let x = *val;
        let x = ((x >> 16) ^ x).wrapping_mul(0x45d_9f3b_u32);
        let x = ((x >> 16) ^ x).wrapping_mul(0x45d_9f3b_u32);
        let x = (x >> 16) ^ x;
        x as usize % max
    }
}

/// Minimal hashing trait
pub trait Hasher<T> {
    fn hash(val: &T, max: usize) -> usize;
}
```

Listing 4.4: probing.rs

```
pub trait Prober {
    fn probe(i: usize) -> usize;
}

pub struct TriangularProber;
```

```
impl Prober for TriangularProber {
    fn probe(i: usize) -> usize {
        (i * (i + 1)) >> 1
    }
}
```

```
pub struct LinearProber;
impl Prober for LinearProber {
    fn probe(i: usize) -> usize {
        i
    }
}
```

```
pub struct QuadraticProber;
impl Prober for QuadraticProber {
    fn probe(i: usize) -> usize {
        i * i
    }
}
```

Listing 4.5: chainingtable.rs

```
use super::{HashTable, Hasher, ELEMENT_COUNT};
use std::marker::PhantomData;

enum LinkedList<T> {
    Cons(T, Box<LinkedList<T>>),
    Nil,
}

impl<T: PartialEq + Copy> LinkedList<T> {
    pub fn contains(&self, searched: &T) -> bool {
        match self {
            LinkedList::Cons(val, other) => *val == *searched || other.contains(searched),
            LinkedList::Nil => false,
        }
    }
}
```

```

    }
}

pub fn push(&mut self, val: T) {
    let push_to_self = match self {
        LinkedList::Cons(_, other) => {
            other.push(val);
            false
        }
        LinkedList::Nil => true,
    };
    if push_to_self {
        *self = LinkedList::Cons(val, Box::new(LinkedList::Nil));
    }
}

pub struct DirectChainingTable<T: PartialEq + Copy, H: Hasher<T>> {
    collisions: usize,
    entries: Vec<Box<LinkedList<T>>>,
    hasher: PhantomData<H>,
}

impl<T: PartialEq + Copy, H: Hasher<T>> Default for DirectChainingTable<T, H> {
    fn default() -> Self {
        Self::with_size(ELEMENT_COUNT)
    }
}

impl<T: PartialEq + Copy, H: Hasher<T>> DirectChainingTable<T, H> {
    fn with_size(size: usize) -> Self {
        let mut entries = Vec::with_capacity(size);
        for _ in 0..size {
            entries.push(Box::new(LinkedList::Nil));
        }
    }
}

```

```

        Self {
            collisions: 0,
            entries,
            hasher: PhantomData,
        }
    }
}

pub struct SeparateChainingTable<T: PartialEq + Copy, H: Hasher<T>> {
    collisions: usize,
    entries: Vec<(Option<T>, Box<LinkedList<T>>>>,
    hasher: PhantomData<H>,
}

impl<T: PartialEq + Copy, H: Hasher<T>> Default for SeparateChainingTable<T, H> {
    fn default() -> Self {
        Self::with_size(ELEMENT_COUNT)
    }
}

impl<T: PartialEq + Copy, H: Hasher<T>> SeparateChainingTable<T, H> {
    fn with_size(size: usize) -> Self {
        let mut entries = Vec::with_capacity(size);
        for _ in 0..size {
            entries.push((None, Box::new(LinkedList::Nil)));
        }
        Self {
            collisions: 0,
            entries,
            hasher: PhantomData,
        }
    }
}

impl<T: PartialEq + Copy, H: Hasher<T>> HashTable<T> for SeparateChainingTable<T, H>

```

```
fn has(&mut self, val: &T) -> bool {
    let index = H::hash(val, self.entries.len());
    if let Some(x) = self.entries[index].0 {
        if x == *val {
            return true;
        }
        self.collisions += 1;
    }
    let mut right_now = self.entries[index].1.as_ref();
    while let LinkedList::Cons(x, new) = right_now {
        if *x == *val {
            return true;
        }
        self.collisions += 1;
        right_now = new.as_ref();
    }
    false
}

fn reset_collisions(&mut self) {
    self.collisions = 0;
}

fn get_collisions(&self) -> usize {
    self.collisions
}

fn insert(&mut self, val: &T) -> bool {
    let index = H::hash(val, self.entries.len());
    if self.entries[index].0.is_none() {
        self.entries[index].0 = Some(*val);
        return true;
    }
    if let Some(x) = self.entries[index].0 {
        if x == *val {
            return true;
        }
    }
}
```

```

    }
    if self.entries[index].1.contains(val) {
        return true;
    }
    self.entries[index].1.push(*val);
    true
}

// the type is kind of complicated for this hash table so some assumptions will be made
// a bucket has size 16, any element that collides with another one takes up 16 bytes
// if we assume that 0.25 of all elements have collided with another, our formula for the size is
// 16*bytes + 0.25*16*elements
fn resize_to_bytes(&mut self, bytes: usize, elements: usize) {
    let available_elements = (bytes / 16) as f64;
    let elements = elements as f64;
    let mut buckets = available_elements as f64;
    let mut step = available_elements as f64 / 2_f64;
    while step > 1_f64 {
        let used_elements = buckets * ((buckets - 1_f64) / buckets).powf(elements);
        if used_elements > available_elements {
            buckets -= step;
        } else if used_elements < available_elements {
            step = step / 2_f64;
            buckets += step;
        }
    }
    if buckets < 1_f64 {
        panic!("invalid configuration for direct chaining table");
    }
    *self = Self::with_size(buckets as usize);
}

}

impl<T: PartialEq + Copy, H: Hasher<T>> HashTable<T> for DirectChainingTable<T, H> {
    fn has(&mut self, val: &T) -> bool {

```



```

    let index = H::hash(val, self.entries.len());
    let mut right_now = self.entries[index].as_ref();
    while let LinkedList::Cons(x, next) = right_now {
        if *x == *val {
            return true;
        }
        self.collisions += 1;
        right_now = next.as_ref();
    }
    false
}

fn reset_collisions(&mut self) {
    self.collisions = 0;
}

fn get_collisions(&self) -> usize {
    self.collisions
}

fn insert(&mut self, val: &T) -> bool {
    let index = H::hash(val, self.entries.len());
    if !self.entries[index].contains(val) {
        self.entries[index].push(*val);
    }
    true
}

// size of direct chaining table is buckets*(size of bucket) + entries*(size of r
// size of bucket is the size of a pointer to a linkedlist = 8
// size of node is the size of a linkedlist node = 16
fn resize_to_bytes(&mut self, bytes: usize, elements: usize) {
    let available_bytes = bytes as isize - (16 * elements) as isize;
    if available_bytes < 1 {
        panic!("not_enough_bytes_available_for_the_buckets");
    }
    *self = Self::with_size(available_bytes as usize / 8);
}

```

```
    }
}
```

Listing 4.6: openaddressing.rs

```
use super::{HashTable, Hasher, Prober, ELEMENT_COUNT};
use std::marker::PhantomData;

// one Option<u32> has size of 8B => 1 << 15 elements have (1 << 18)B size ~262kB
pub struct OpenAddressingTable<T: PartialEq + Copy, P: Prober, H: Hasher<T>> {
    collisions: usize,
    entries: [Option<T>; ELEMENT_COUNT],
    prober: PhantomData<P>,
    hasher: PhantomData<H>,
}

impl<T: PartialEq + Copy, P: Prober, H: Hasher<T>> Default for OpenAddressingTable<T, P, H> {
    fn default() -> Self {
        Self {
            collisions: 0,
            entries: [None; ELEMENT_COUNT],
            prober: PhantomData,
            hasher: PhantomData,
        }
    }
}

impl<T: PartialEq + Copy, H: Hasher<T>, P: Prober> HashTable<T> for OpenAddressingTable<T, P, H> {
    fn has(&mut self, val: &T) -> bool {
        let mut index = H::hash(val, self.entries.len());
        let mut attempts = 0;
        while attempts < self.entries.len() {
            if let Some(inside) = self.entries[index] {
                if inside == *val {
                    return true;
                }
            }
            index = (index + 1) % self.entries.len();
            attempts += 1;
        }
        false
    }
}
```

```
        }
    } else {
        return false;
    }
    attempts += 1;
    self.collisions += 1;
    index = (index + P::probe(attempts)) % self.entries.len();
}
false
}
fn reset_collisions(&mut self) {
    self.collisions = 0;
}
fn get_collisions(&self) -> usize {
    self.collisions
}
fn insert(&mut self, val: &T) -> bool {
    if self.has(val) {
        return true;
    }
    let mut index = H::hash(val, self.entries.len());
    let mut attempts = 0;
    while attempts < self.entries.len() {
        if self.entries[index].is_none() {
            self.entries[index] = Some(*val);
            return true;
        }
        attempts += 1;
        index = (index + P::probe(attempts)) % self.entries.len();
    }
    false
}
fn resize_to_bytes(&mut self, bytes: usize, elements: usize) {
    if elements > ELEMENT_COUNT {
```

```

        panic!("trying to insert more elements than possible by constraint");
    }
    if bytes >> 3 != ELEMENT_COUNT {
        panic!("trying to resize to invalid size");
    }
}
}
}

```

Listing 4.7: coalescedtable.rs

```

use super::{HashTable, Hasher, ELEMENT_COUNT};
use std::marker::PhantomData;

// one Option<(T, Option<usize>>) has size 24 => Can only use 10.922 buckets to only
pub struct CoalescedTable<T: PartialEq + Copy, H: Hasher<T>> {
    collisions: usize,
    entries: Vec<Option<(T, Option<usize>>>>,
    hasher: PhantomData<H>,
    cursor: usize,
}

impl<T: PartialEq + Copy, H: Hasher<T>> Default for CoalescedTable<T, H> {
    fn default() -> Self {
        Self::with_size(ELEMENT_COUNT)
    }
}

impl<T: PartialEq + Copy, H: Hasher<T>> CoalescedTable<T, H> {
    fn with_size(size: usize) -> Self {
        let mut entries = Vec::with_capacity(size);
        for _ in 0..size {
            entries.push(None);
        }
        Self {
            collisions: 0,
            entries,

```

```
        hasher: PhantomData,  
        cursor: 0,  
    }  
}  
}  
  
impl<T: PartialEq + Copy, H: Hasher<T>> HashTable<T> for CoalescedTable<T, H> {  
    fn has(&mut self, val: &T) -> bool {  
        let mut index = H::hash(val, self.entries.len());  
        if self.entries[index].is_none() {  
            self.entries[index] = Some((*val, None));  
            return true;  
        }  
        self.collisions += 1;  
        loop {  
            if let Some((x, next)) = self.entries[index] {  
                if x == *val {  
                    return true;  
                }  
                self.collisions += 1;  
                if let Some(i) = next {  
                    index = i;  
                } else {  
                    break;  
                }  
            } else {  
                panic!("data_inconsistency");  
            }  
        }  
        false  
    }  
    fn reset_collisions(&mut self) {  
        self.collisions = 0;  
    }  
}
```

```
fn get_collisions(&self) -> usize {
    self.collisions
}

fn insert(&mut self, val: &T) -> bool {
    let mut index = H::hash(val, self.entries.len());
    if self.entries[index].is_none() {
        self.entries[index] = Some((*val, None));
        return true;
    }
    loop {
        if let Some((x, next)) = self.entries[index] {
            if x == *val {
                return true;
            }
            if let Some(i) = next {
                index = i;
            } else {
                break;
            }
        } else {
            panic!("data_inconsistency");
        }
    }
    while self.cursor < self.entries.len() {
        if self.entries[self.cursor].is_none() {
            self.entries[self.cursor] = Some((*val, None));
            let old = self.entries[index].expect("data_inconsistency").0;
            self.entries[index] = Some((old, Some(self.cursor)));
            return true;
        }
        self.cursor += 1;
    }
    true
}
```

```

fn resize_to_bytes(&mut self, bytes: usize, elements: usize) {
    let entries = bytes / 24;
    if entries < elements {
        panic!("cannot_resize_that_low");
    }
    *self = Self::with_size(entries);
}
}

```

Listing 4.8: logging.rs

```

use gnuplot::{AxesCommon, Caption, Figure, Graph};
use std::fs::OpenOptions;
use std::io::Write;

pub fn print_header(name: &str, load_factors: &[f64]) {
    let mut out = format!("{:20}", name);
    for (i, lambda) in load_factors.iter().enumerate() {
        let lambda = format!("{:0.0}%", lambda * 100_f64);
        out.push_str(&format!("{:~5}", lambda));
        if i != load_factors.len() - 1 {
            out.push_str("|");
        }
    }
    println!("{}", out);
}

pub fn print_subtable(name: &str, stats: &[(f32, f64, f32, f64)], load_factors: &[f64]) {
    println!();
    print_header(name, load_factors);
    let mut out = format!("{:20}", "+_collisions");
    for i in 0..stats.len() {
        out.push_str(&format!("{:~5.2}", stats[i].0));
        if i != stats.len() - 1 {

```

```

        out.push_str("|");
    }
}
println!("{}", out);
let mut out = format!("{:20}", "+_time[ns]");
for i in 0..stats.len() {
    out.push_str(&format!("{:~5.2}", stats[i].1));
    if i != stats.len() - 1 {
        out.push_str("|");
    }
}
println!("{}", out);
let mut out = format!("{:20}", "-_collisions");
for i in 0..stats.len() {
    out.push_str(&format!("{:~5.2}", stats[i].2));
    if i != stats.len() - 1 {
        out.push_str("|");
    }
}
println!("{}", out);
let mut out = format!("{:20}", "-_time[ns]");
for i in 0..stats.len() {
    out.push_str(&format!("{:~5.2}", stats[i].3));
    if i != stats.len() - 1 {
        out.push_str("|");
    }
}
println!("{}", out);
}

```

```

pub fn write_csv(all_stats: &[(String, Vec<(f32, f64, f32, f64)>)], load_factors: &[f64]) {
    let mut file = OpenOptions::new()
        .create(true)
        .write(true)

```



```

        .truncate(true)
        .open("hashset_data.csv")
        .expect("Could not open file to write output analysis to");
let mut header = String::new();
header.push_str("\"Name\",");
for lambda in load_factors {
    let percentage = format!("{:.0}%", lambda * 100_f64);
    header.push_str(&format!("\"Success_Collisions({0})\", \"Success_Time({0})[ns]\""));
}
header.push_str("\r\n");
file.write_all(header.as_bytes())
    .expect("Could not write to file");
for (name, stats) in all_stats {
    let mut f = format!("\"{}\"", name);
    for stat in stats {
        f.push_str(&format!("{}", stat.0, stat.1, stat.2, stat.3));
    }
    f.push_str("\n");
    file.write_all(f.as_bytes())
        .expect("Could not write to file");
}
}

pub fn write_graphs(all_stats: &[(String, Vec<(f32, f64, f32, f64)>)], load_factors:
    let mut fg = Figure::new();
    let ax = fg
        .axes2d()
        .set_title("Collisions on success", &[])
        .set_legend(Graph(0.5), Graph(0.9), &[], &[])
        .set_x_label("Number of elements", &[])
        .set_y_label("Collisions", &[]);
    for (name, stats) in all_stats {
        ax.lines(
            load_factors

```

```
        .iter()
        .map(|x| (x * element_count as f64) as usize),
    stats.iter().map(|x| x.0),
    &[Caption(&name)],
);
}
fig.save_to_png("./graphs/successful_collisions.png", 1920, 1080)
    .expect("Could not save file");

let mut fg = Figure::new();
let ax = fg
    .axes2d()
    .set_title("Collisions on failure", &[])
    .set_legend(Graph(0.5), Graph(0.9), &[], &[])
    .set_x_label("Number of elements", &[])
    .set_y_label("Collisions", &[]);
for (name, stats) in all_stats {
    ax.lines(
        load_factors
            .iter()
            .map(|x| (x * element_count as f64) as usize),
        stats.iter().map(|x| x.2),
        &[Caption(&name)],
    );
}
fig.save_to_png("./graphs/failure_collisions.png", 1920, 1080)
    .expect("Could not save file");

let mut fg = Figure::new();
let ax = fg
    .axes2d()
    .set_title("Time on success", &[])
    .set_legend(Graph(0.5), Graph(0.9), &[], &[])
    .set_x_label("Number of elements", &[])
```

```
.set_y_label("time[ns]", &[]);
for (name, stats) in all_stats {
    ax.lines(
        load_factors
            .iter()
            .map(|x| (x * element_count as f64) as usize),
        stats.iter().map(|x| x.1),
        &[Caption(&name)],
    );
}
fig.save_to_png("./graphs/successful_time.png", 1920, 1080)
    .expect("Could not save file");

let mut fg = Figure::new();
let ax = fg
    .axes2d()
    .set_title("Time on failure", &[])
    .set_legend(Graph(0.5), Graph(0.9), &[], &[])
    .set_x_label("Number of elements", &[])
    .set_y_label("time[ns]", &[]);
for (name, stats) in all_stats {
    ax.lines(
        load_factors
            .iter()
            .map(|x| (x * element_count as f64) as usize),
        stats.iter().map(|x| x.3),
        &[Caption(name)],
    );
}
fig.save_to_png("./graphs/failure_time.png", 1920, 1080)
    .expect("Could not save file");
}
```